


• Experimental Results (30%)


- *我在前 4M step 因為 clip epsilon 設錯,導致前 4M 學習效果並不是很好,在 後面 4M 重新修正結果後,效果有明顯上升
- *原本跑到 7M 修正上述錯誤並從 4M 時的 model 重新開始訓練。而誤會繪圖的方式錯把初始 step 設為 4M(應該要為最後跑),因此於 4M 出現分岔。我以紅色箭頭註記修正後的紀錄結果




















- Answer the questions (bonus) (20%)
- 1. PPO is an on-policy or an off-policy algorithm? Why? (5%)

PPO 是 on-policy,因為它使用正在 train 的 model 來與環境互動

2. Explain how PPO ensures that policy updates at each step are not too large to avoid destabilization. (5%)

 $r_t(\theta)\widetilde{A_t}$ 表示每次往 gradient 最大方向更新的距離,如果此值太大容易造成不穩定。PPO 使用 clip 來使得每次更新的距離($move\ lenght$)介於

$$move\ lenght < (1-\varepsilon)\widetilde{A_t}$$
 , if $\widetilde{A_t} < 0$ $move\ lenght < (1+\varepsilon)\widetilde{A_t}$, if $\widetilde{A_t} > 0$ 如此保證不會一次太大步而不穩定

3. Why is GAE-lambda used to estimate advantages in PPO instead of just one-step advantages? How does it contribute to improving the policy learning process? (5%)

$$\widetilde{A_t}^{GAE(\gamma,\lambda)} = (\delta_t^V + (\lambda\gamma)^1 \delta_{t+1}^V + \dots + (\lambda\gamma)^k \delta_{t+k}^V + \dots)$$

One-step advantage
$$\widetilde{A_t}^{GAE(\gamma,0)} = \widetilde{A_t}^{(1)} = TD_error$$

其只考慮了下一步的結果所產生的 TD error 並以此來衡量 action 的好壞,但由於整個過程是 stochastic 可能只是剛好此次結果好/不好下次就是不好/好,其後續有很大的 variance,因此採用 Lambda-GAE 方式多考慮更長遠的結果來減少 variance 以此減少 variance 避免偶而遇到的極糟情況讓整個 model 壞掉。

4. Please explain what the lambda parameter represents in GAE-lambda, and how adjusting the lambda parameter affects the training process and performance of PPO? (5%)

Lambda 的大小用來調整要考慮非常長遠還是近期就好,當 Lambda 越小時,model 的 bias 越低但隨之而來的 variance 也越高,對 noise 的對抗性越低,容易在訓練過程 model 一遇到很糟狀況而被拖垮;反之如果太高則 model 的準確度越低(bias 大),但對 noise 容忍度較高幫助 model 穩定